

Predicción de Resultados del Fútbol Uruguayo Mediante Algoritmos de Aprendizaje Automático Supervisado

Anastasia Martucci, *Estudiante, Udelar*, Fernando Horita Siratuti, *Estudiante, Udelar*, y Julián Ismael Martínez Silva, *Estudiante, Udelar*

Abstract—Este artículo presenta un enfoque experimental exhaustivo para la predicción de resultados en partidos del fútbol uruguayo utilizando algoritmos de aprendizaje automático supervisado. A partir de un conjunto de datos histórico que abarca desde 1932 hasta 2025, se implementa un pipeline de preprocesamiento reproducible y una partición temporal estricta para mitigar el riesgo de fuga de información. Se evalúan y comparan rigurosamente modelos desarrollados ad-hoc (un clasificador base histórico, un árbol de decisión con pre-poda basada en ganancia de información mínima y un clasificador Naive Bayes con suavizado por estimación m) frente a arquitecturas de referencia provistas por *scikit-learn* [4] como Random Forest y CategoricalNB. Los resultados demuestran que los modelos de ensamble y las variantes probabilísticas optimizadas superan consistentemente al clasificador base, alcanzando un desempeño competitivo en una tarea intrínsecamente estocástica, a la vez que se discuten analíticamente las limitaciones metodológicas en la predicción de la clase minoritaria de empates [1], [2], [3].

Index Terms—Aprendizaje Automático, Predicción de Fútbol, Árboles de Decisión, Naive Bayes, Series Temporales, Validación Temporal.

I. INTRODUCCIÓN

PREDECIR el resultado de un evento deportivo competitivo, como un partido de fútbol, representa un desafío complejo dentro de las ciencias de datos y el aprendizaje automático. La alta estocasticidad inherente al deporte, sumada a la multiplicidad de factores exógenos y variables latentes que influyen en el desarrollo de un encuentro, dificulta la tarea de generalización de los algoritmos predictivos. En el marco del curso de Aprendizaje Automático de la Facultad de Ingeniería (Universidad de la República, Udelar) [1], este trabajo aborda la tarea de predecir el resultado de partidos oficiales del fútbol uruguayo bajo un esquema de clasificación multiclase de tres posibles salidas: victoria local ('L'), victoria visitante ('V') o empate ('E').

Para resolver este problema de manera metodológicamente rigurosa, se procesa un subconjunto histórico de partidos comprendido entre los años 1932 y 2025. Dado el carácter evolutivo de los datos deportivos y la dependencia temporal de las estadísticas acumuladas, la estrategia de partición debe respetar estrictamente el orden cronológico para evitar sesgos de filtración de información (*data leakage*) [2]. Por consiguiente, los encuentros disputados hasta el año 2023 se destinan

al entrenamiento y validación cruzada mediante particiones cronológicas específicas (*TimeSeriesSplit*), mientras que el conjunto de evaluación independiente (*test*) se reserva de forma exclusiva para los años 2024 y 2025.

El presente artículo detalla el diseño de un pipeline de preprocesamiento automatizado y reproducible, la formulación matemática e implementación desde cero de algoritmos clásicos de clasificación, su comparativa cuantitativa y cualitativa frente a modelos avanzados de *scikit-learn* [4], y un análisis crítico de las métricas de rendimiento obtenidas [1], [2], [3].

II. PREPROCESAMIENTO Y ANÁLISIS DE DATOS

Para garantizar la reproducibilidad experimental y asegurar la integridad de los datos de entrada, se diseñó un *pipeline* de preprocesamiento unificado mediante la biblioteca *scikit-learn* [4]. El conjunto de datos original, que recopila los registros históricos del fútbol uruguayo, fue sometido a las siguientes etapas de transformación y limpieza [1]:

- **Limpieza y Filtrado Estructural:** Se eliminaron registros duplicados exactos y se unificaron los nombres de los clubes participantes para evitar discrepancias sintácticas en las variables categóricas.
- **Definición de la Clase Objetivo:** La variable dependiente o *target* (*ganador*) se estructuró en tres categorías discretas: 'L' (victoria del equipo local), 'V' (victoria del equipo visitante) y 'E' (empate). Aquellos encuentros definidos mediante tiros desde el punto penal se computaron formalmente como empates al haber concluido en igualdad durante el tiempo reglamentario.
- **Ingeniería de Características Temporales:** Se implementó un transformador especializado (*TeamFormTransformer*) encargado de calcular la tasa de rendimiento histórico reciente de cada institución mediante una ventana deslizante de los últimos diez años (*home_form* y *away_form*), dotando a los modelos de contexto estadístico previo al encuentro. Para reflejar el nivel real de las escuadras, este rendimiento se calcula de manera global, concatenando los historiales del equipo tanto en condición de local como de visitante. La prevención de fuga de datos (*data leakage*) a nivel de ingeniería de características se garantizó aplicando una desigualdad temporal estricta, asegurando que el partido a predecir quede matemáticamente excluido del cálculo

de sus propios antecedentes. Adicionalmente, se diseñó una estrategia de imputación para mitigar el problema de arranque en frío (*Cold Start*), común en equipos recién ascendidos: si un club carece de historial en la ventana estipulada, se le asigna una probabilidad de victoria neutra de 0.5. Finalmente, dado que *home_form* y *away_form* son variables continuas con un valor prácticamente único por partido, se redondearon a dos decimales previo al entrenamiento del árbol propio. Esta discretización reduce drásticamente el número de umbrales candidatos evaluados en cada nodo (de miles a un centenar aproximadamente), mitigando el costo computacional cuadrático inherente a la búsqueda exhaustiva de cortes en variables numéricas de alta cardinalidad.

- **Codificación Categórica:** Las variables nominales correspondientes a las identidades de los equipos y las marcas temporales (año y mes) se transformaron mediante técnicas de codificación vectorial (*One-Hot Encoding* y *Ordinal Encoder*), garantizando la compatibilidad matemática con los clasificadores matriciales y probabilísticos.

A. Análisis Exploratorio y Distribución de Clases

Un aspecto crítico revelado durante el análisis exploratorio del conjunto de entrenamiento es el desbalance intrínseco de las clases objetivo. Las victorias del equipo local ('L') exhiben una superioridad porcentual significativa en comparación con los empates ('E') y las victorias visitantes ('V'). Esta asimetría estadística condiciona fuertemente a los clasificadores basados en conteo de frecuencias, motivando la necesidad de emplear métricas robustas al desbalance como el *Macro-F1*, el cual evita que los modelos maximicen su rendimiento ignorando las clases minoritarias.

III. METODOLOGÍA Y VALIDACIÓN TEMPORAL

Dada la naturaleza secuencial y temporal de los datos deportivos, la partición de los conjuntos de entrenamiento y evaluación no puede abordarse mediante muestreo aleatorio uniforme. Para preservar la causalidad temporal, se adoptó la partición cronológica estricta [1]:

$$D_{train} = \{t \leq 2023\}, \quad D_{test} = \{2024 \leq t \leq 2025\} \quad (1)$$

donde el conjunto de entrenamiento abarca los partidos jugados hasta 2023 inclusive, y el conjunto de evaluación comprende de manera exclusiva los años 2024 y 2025.

A. Estrategia de Validación con TimeSeriesSplit

Para la optimización de hiperparámetros mediante búsqueda en grilla (*GridSearchCV*), el uso de validación cruzada estándar (*k-fold* aleatorio) introduciría una fuga severa de información, ya que datos futuros se utilizarían para predecir eventos pasados. Para solventar esto, se implementó *TimeSeriesSplit* con 5 particiones progresivas. En cada iteración, el conjunto de entrenamiento se expande cronológicamente, emulando un escenario real de predicción prospectiva.

IV. IMPLEMENTACIÓN DE MODELOS SUPERVISADOS

A. Clasificador Base y Árbol de Decisión Propio

- 1) **Clasificador Base Heurístico:** Un modelo de referencia desarrollado ad-hoc que predice sistemáticamente la victoria del equipo con mayor proporción histórica de partidos ganados en general considerando los últimos diez años previos a la fecha del encuentro [1]. En los casos de empate técnico entre ambas proporciones históricas (incluyendo la ausencia total de antecedentes para alguno de los equipos, tratada como proporción nula) el clasificador predice 'E' por defecto.
- 2) **Árbol de Decisión Propio:** Implementación modular basada en el algoritmo ID3 [5], que incorpora un hiperparámetro de pre-poda denominado *min_info_gain*. Este criterio detiene de forma recursiva la ramificación del árbol cuando ningún atributo disponible supera una ganancia mínima de información [2]:

$$\text{Ganancia}(S, A) = \text{Entropía}(S) - \sum_{v \in \text{val}(A)} \frac{|S_v|}{|S|} \text{Entropía}(S_v) \quad (2)$$

TABLE I
MUESTRA DE PREDICCIONES DEL CLASIFICADOR BASE (PRIMEROS 5 PARTIDOS DE 2024)

Local	Visitante	Predicción	Real
Nacional	River Plate	L	L
CA Fenix	Danubio	V	V
Miramar Misiones	CA Progreso	V	V
Deportivo Maldonado	Boston River	E	V
CA Cerro	Montevideo Wanderers	V	E

La implementación soporta de manera unificada tanto atributos categóricos como numéricos dentro del mismo árbol: para atributos categóricos (identidad del equipo, por ejemplo) la partición es multivaluada, generando un nodo hijo por cada valor observado en el conjunto de entrenamiento. Además, para atributos numéricos (tasa de victoria reciente, año, mes) se evalúa como candidato de corte cada punto medio entre valores consecutivos ordenados, seleccionando el umbral que maximiza la ganancia de información. Ante un valor categórico no observado durante el entrenamiento (por ejemplo, un equipo ausente en ese subconjunto particular), el árbol recurre a la clase mayoritaria del nodo como mecanismo de respaldo, evitando fallos en tiempo de inferencia.

B. Clasificadores Naive Bayes y Ensembles

- 3) **Naive Bayes Propio:** Clasificador probabilístico que modela la distribución condicional de las características asumiendo independencia condicional, incorporando suavizado por estimación *m* (*m*-estimate) [5] para prevenir probabilidades nulas ante ocurrencias escasas [3]:

$$P(a_i | v_j) = \frac{n_c + m \cdot p}{n + m} \quad (3)$$

Para garantizar estabilidad numérica y prevenir el desbordamiento por subdesbordamiento (*underflow*), los

cálculos de probabilidad conjunta se implementaron y operaron en el espacio logarítmico. Cabe destacar que, si bien esta implementación ad-hoc y el modelo de referencia *CategoricalNB* de *scikit-learn* parten de formulaciones de suavizado ligeramente distintas (el hiperparámetro m en un caso, y el hiperparámetro α propio de *scikit-learn* en el otro), sus resultados sobre el conjunto de test resultaron ser *idénticos* (Tabla II): ambos clasificadores coincidieron en la predicción de los 472 partidos del conjunto de evaluación (Accuracy 0.483, Macro-F1 0.380 en los dos casos). Esta equivalencia empírica se explica por el reducido espacio de atributos utilizado por ambos modelos (únicamente la identidad de los equipos local y visitante); con un volumen de datos de entrenamiento suficientemente grande para las combinaciones de equipos observadas, el efecto del término de suavizado sobre la clase predicha se vuelve marginal, independientemente del hiperparámetro concreto utilizado para regularizarlo, de modo que ambas implementaciones convergen a la misma regla de decisión práctica.

- 4) **CategoricalNB y Random Forest:** Como modelos de referencia provistos por *scikit-learn* [4], se evaluó *CategoricalNB* y *Random Forest*, un modelo de ensamble basado en *bagging* de múltiples árboles diseñado para reducir la varianza y mitigar el sobreajuste estructural [6].

V. OPTIMIZACIÓN DE HIPERPARÁMETROS Y EXPERIMENTACIÓN

La búsqueda de hiperparámetros óptimos se ejecutó de forma sistemática mediante validación cruzada temporal (*TimeSeriesSplit*).

- **Árbol de Decisión:** Se exploró una grilla para $\min_info_gain \in [0.0, 0.0005, 0.001, 0.005, 0.01, 0.05]$. Las curvas de error demostraron que valores cercanos a 0.0 maximizaban la métrica en validación, evidenciando una alta propensión a la memorización de instancias de entrenamiento.
- **Naive Bayes Propio:** Se evaluó el parámetro $m \in [0.01, 0.1, 0.5, 1, 2, 5, 10, 20, 50]$. El análisis demostró que el valor de m tuvo un impacto marginal en la métrica final (con variaciones confinadas al cuarto decimal). Esto indica que, para este espacio de características de baja cardinalidad, el extenso volumen de datos de entrenamiento (≈ 14.700 partidos) es lo suficientemente robusto como para dominar sobre el prior uniforme del suavizado estadístico.

A. Definición Formal de Métricas

Para un problema multiclase con clases $C = \{L, E, V\}$, el *Accuracy* mide la proporción global de aciertos, mientras que el *Macro-F1* se define como el promedio no ponderado de la puntuación F_1 obtenida en cada clase individual:

$$\text{Macro-F1} = \frac{1}{|C|} \sum_{c \in C} \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (4)$$

Esta formulación garantiza que un fallo sistemático en clases minoritarias (como los empates) penalice de manera justa el resultado global del clasificador. Para contrastar el desempeño empírico de las distintas arquitecturas bajo este rigor metodológico, la Tabla II detalla los resultados cuantitativos globales obtenidos en el conjunto de test independiente (2024-2025) [2], [3]. Se observa que tanto la formulación probabilística del Naive Bayes Propio (idéntica en este caso a *CategoricalNB*) como el ensamble de *Random Forest* superan en *Macro-F1* al árbol de decisión simple, alcanzando índices competitivos en torno a 0.38–0.39. Sin embargo, en términos de *Accuracy* el clasificador base heurístico resulta sorprendentemente competitivo, incluso superando a *Random Forest* (0.462 frente a 0.420); esta aparente paradoja refuerza el argumento metodológico central de este trabajo: el clasificador base maximiza los aciertos apoyándose fuertemente en la clase mayoritaria ('L'), mientras que su *Macro-F1* inferior (0.362) delata su bajo desempeño en las clases minoritarias, justificando la elección de esta última métrica como criterio principal de comparación.

TABLE II
DESEMPEÑO GLOBAL DE LOS CLASIFICADORES EN EL CONJUNTO DE TEST (2024-2025)

Modelo	Accuracy	Macro-F1
Clasificador Base (10 Años)	0.462	0.362
Árbol de Decisión Propio ($\min_info_gain$)	0.347	0.341
Random Forest (Scikit-Learn)	0.420	0.390
Naive Bayes Propio (m -estimate)	0.483	0.380
CategoricalNB (Scikit-Learn)	0.483	0.380

B. Análisis Cualitativo y Diagnóstico de Sobreajuste

El examen detallado de las matrices de confusión y la evolución de los errores predictivos, obtenidas a partir de la experimentación documentada [2], [3], permite extraer reflexiones críticas sobre el comportamiento de los algoritmos. Por ejemplo, como se ilustra explícitamente en la Fig. 1, el ensamble de *Random Forest* logra que el error de validación continúe disminuyendo de forma estable a medida que aumenta la profundidad máxima, incluso cuando el error de entrenamiento cae abruptamente a cero. Esta divergencia, que en un árbol de decisión individual sería una clara señal de alarma por memorización, evidencia la robustez estructural del mecanismo de *bagging* frente al sobreajuste. En adición a este fenómeno estadístico, se destacan los siguientes puntos:




Fig. 1. Evolución del error de clasificación en función de la profundidad máxima del árbol para el modelo Random Forest (200 estimadores).




Fig. 2. Matrices de confusión comparativas obtenidas en el conjunto de prueba (2024-2025) para el Árbol de Decisión Propio y Random Forest.

- **Sesgo de Localía y Predicción de Empates ('E'):** Como se hace evidente al comparar las matrices de la Fig. 2, la totalidad de los modelos experimenta una marcada dificultad para anticipar empates. El análisis cualitativo reveló que el tipo de error más frecuente consiste en predecir una victoria local ('L') en partidos que resultaron empatados. Al carecer de atributos que expresen la diferencia de nivel o *forma relativa* entre ambos equipos en un encuentro puntual, las probabilidades condicionales son dominadas sistemáticamente por el histórico efecto de la ventaja de localía. Dado que el *Macro-F1* promedia el rendimiento de manera equitativa por clase, este fenómeno penaliza numéricamente el resultado, explicando la brecha analítica entre el *Accuracy* global y el puntaje de *Macro-F1*.
- **Evaluación del Sobreajuste Estructural:** El árbol de decisión propio exhibió un rendimiento casi absoluto en la etapa de entrenamiento (*Accuracy* ≈ 0.99), sufriendo una importante caída de generalización en test. La variación del hiperparámetro *min_info_gain* demostró que la pre-poda basada exclusivamente en ganancia de información resulta insuficiente por sí sola para frenar el crecimiento excesivo de hojas en conjuntos de datos ruidosos, justificando firmemente la adopción de arquitecturas de ensamble por *bagging*.

- **Descarte de la Hipótesis de Sesgo por Alta Cardinalidad:** Se evaluó la posibilidad de que el desempeño limitado del árbol propio respondiera a un sesgo conocido del criterio de ganancia de información, que tiende a favorecer atributos con numerosos valores posibles (como la identidad de los 40+ equipos) por sobre atributos de menor cardinalidad. Para contrastar esta hipótesis, se repitió el entrenamiento y la búsqueda de *min_info_gain* (ampliando la grilla hasta 0.5) excluyendo por completo las variables de identidad del equipo. Como se detalla empíricamente en la Tabla III, el resultado sin estas variables (*Macro-F1* de 0.337) fue prácticamente idéntico al obtenido con ellas incluidas (0.341), manteniendo además una *accuracy* de entrenamiento sumamente elevada (≈ 0.98). Esto permitió descartar la hipótesis de sesgo y reforzó la conclusión de que la limitación es netamente estructural: el uso exclusivo de *min_info_gain* como criterio de parada, sin restricción de profundidad máxima ni de tamaño mínimo de hoja, resulta insuficiente para prevenir el sobreajuste en nodos con pocos ejemplos, independientemente del conjunto de atributos disponible.

TABLE III
IMPACTO DE LAS VARIABLES DE IDENTIDAD DE EQUIPO EN EL SOBREAJUSTE DEL ÁRBOL DE DECISIÓN

Configuración	min_info_gain	Macro-F1 (Test)	Acc. (Train)
Con home/away (Grilla orig.)	0.0	0.341	0.9994
Sin home/away (Grilla ampl.)	0.0	0.337	0.9789

VI. CONCLUSIONES

Este trabajo evidenció que la predicción de marcadores en el fútbol uruguayo constituye una tarea de alta complejidad debido a la naturaleza estocástica del deporte. La estructuración de un pipeline de datos reproducible y el respeto estricto de la partición temporal permitieron evaluar de forma honesta y metodológica los algoritmos supervisados [1], [2], [3]. Como líneas de trabajo futuro, se propone la incorporación de variables relativas avanzadas (tales como diferencias directas de rendimiento reciente y estadísticas de enfrentamientos directos *head-to-head*) para potenciar la sensibilidad de los modelos ante partidos cerrados y empates.

DECLARACIÓN SOBRE EL USO DE INTELIGENCIA ARTIFICIAL

De conformidad con las directrices institucionales de la Facultad de Ingeniería (UdelaR) relativas al uso ético y crítico de la inteligencia artificial bajo la Categoría 3 (uso extensivo), se declara el empleo de herramientas de modelos de lenguaje, específicamente Gemini [7] y Claude [8], para la depuración sintáctica de código y la revisión de estilo formal de este documento. Toda la arquitectura lógica, la experimentación computacional, la interpretación técnica de los resultados y el análisis crítico de las métricas fueron desarrollados, validados y asumidos en su totalidad por los integrantes del grupo.

REFERENCES

- [1] A. Martucci *et al.*, *01_eda_pipeline.ipynb*, Repositorio del Proyecto de Aprendizaje Automático, Facultad de Ingeniería, Udelar, 2026. [En línea]. Disponible: https://github.com/fernando-horita-siratuti/Prediccion-de-Resultados-del-Futbol-Uruguay/blob/main/notebooks/01_eda_pipeline.ipynb
- [2] F. Horita Siratuti *et al.*, *02_sandbox_arbol.ipynb*, Repositorio del Proyecto de Aprendizaje Automático, Facultad de Ingeniería, Udelar, 2026. [En línea]. Disponible: https://github.com/fernando-horita-siratuti/Prediccion-de-Resultados-del-Futbol-Uruguay/blob/main/notebooks/02_sandbox_arbol.ipynb
- [3] J. Martínez Silva *et al.*, *03_sandbox_nb.ipynb*, Repositorio del Proyecto de Aprendizaje Automático, Facultad de Ingeniería, Udelar, 2026. [En línea]. Disponible: https://github.com/fernando-horita-siratuti/Prediccion-de-Resultados-del-Futbol-Uruguay/blob/main/notebooks/03_sandbox_nb.ipynb
- [4] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [En línea]. Disponible: <https://jmlr.csail.mit.edu/papers/volume12/pedregosa11a/pedregosa11a.pdf>
- [5] T. M. Mitchell, *Machine Learning*. New York, NY, USA: McGraw-Hill, 1997. Disponible: <https://www.cs.cmu.edu/~tom/files/MachineLearningTomMitchell.pdf>
- [6] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. [En línea]. Disponible: <https://doi.org/10.1023/A:1010933404324>
- [7] Google, *Gemini Advanced* (Large Language Model), 2026. [En línea]. Disponible: <https://gemini.google.com/>. Nota metodológica: Utilizado para la revisión de estilo y sintaxis técnica del documento bajo el siguiente *prompt*: "Actúa como un revisor académico experto en Inteligencia Artificial y Machine Learning. Lee el siguiente borrador de nuestro artículo científico. Tu tarea es corregir errores gramaticales, ortográficos y de puntuación, además de mejorar la fluidez técnica y el estilo de redacción para que cumpla con los más altos estándares de publicación del IEEE, sin alterar los resultados ni la metodología original."
- [8] Anthropic, *Claude 5 Sonnet* (Large Language Model), 2026. [En línea]. Disponible: <https://claude.ai/>. Nota metodológica: Utilizado para la revisión de estilo y sintaxis técnica del documento bajo el siguiente *prompt*: "Actúa como un revisor académico experto en Inteligencia Artificial y Machine Learning. Lee el siguiente borrador de nuestro artículo científico. Tu tarea es corregir errores gramaticales, ortográficos y de puntuación, además de mejorar la fluidez técnica y el estilo de redacción para que cumpla con los más altos estándares de publicación del IEEE, sin alterar los resultados ni la metodología original."